Langages - Automates déterministes

2023 - Semestre $4\,;$ IUT Informatique Montpellier-Sète

Chapitre 1. Mots - Langages

1)Mots, langages

On se donne un <u>alphabet</u> fini; par exemple X={a, b}

Alors:

- un mot sur X est une suite finie
 d'éléments de X. (par ex. aaab, baa ou aaabb qui peut se noter a³b² ...)
- il y a un mot vide noté ε.
- L'ensemble de tous les mots est noté X*.

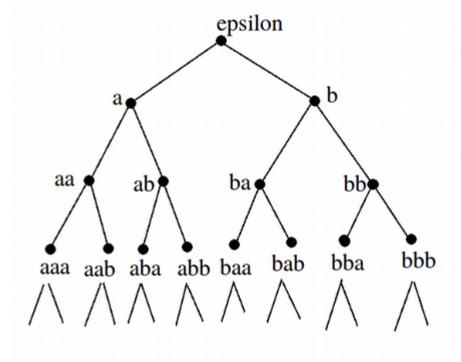
2

Notations:

- Soit m = abcba un mot sur l'alphabet X={a, b, c}.
 - -La longueur de m est le nombre de « lettres » de m et est notée|m|(dans notre exemple|m|=5). On a $|\epsilon|$ = 0.
 - Pour i∈{1, 2, ..., |m|}, on note m[i] la ième lettre de m(dans notre exemple m[3]=c).
 - On note $|m|_a$ le nombre de a dans le mot m.

Représentation de X*

 $X=\{a,b\}$



4

Exemples de X*

1)
$$X = \emptyset = X^* = \{ \epsilon \}$$

2)
$$X=\{ | \}=>X*=\{ \epsilon, |, ||, |||, ||||, ... \}$$

• On définit une loi interne sur X*:

la concaténation

- Pour tout mot m de X* on a m•ε=ε•m=m
- Sinon, soient $m=m_1m_2....m_k$ et $n=n_1n_2....n_l$ deux mots de X* alors: $m \cdot n = m_1m_2....m_k n_1n_2....n_l$.
 - Exemples:

```
aabb •abb = aabbabb
ab •ab •ab •ab = abababab=(ab)<sup>4</sup>
```

6

Attention:

ε n'est pas une lettre.

L'écriture aɛbb est incorrecte pour un mot.

Par contre on peut écrire a•ɛ•bb=abb

Le monoïde

X* muni de l'opération de concaténation a une structure de **monoïde**

(i.e. • est **associative** et X* possède un **élément neutre** pour cette opération).

8

Vocabulaire:

Soient \mathbf{u} , $\mathbf{m} \in X^*$. \mathbf{u} est un facteur de \mathbf{m} lorsqu'il existe deux mots \mathbf{v} , $\mathbf{w} \in X^*$ tels qu'on puisse écrire:

 $m = v \cdot u \cdot w$.

Dans le cas particulier où v = ε (resp. w = ε), on dit que u est un facteur gauche (resp. facteur droit) ou encore un préfixe (resp. suffixe) de m^Ω

Sous-mots

Soient u, $m \in A^*$.

u est un **sous-mot** de m lorsque u est une **sous-suite extraite** de m.

(donc m est un sur-mot de u)

10

Exemples:

On considère le mot MANGER :

ANG est un facteur qui n'est ni préfixe ni suffixe

MA est un facteur préfixe

GER est un facteur suffixe

MAGR est un sous-mot qui n'est pas un facteur.

MANGER est un facteur et un sous-mot.

De même ε est un facteur et un sous-mot.

Exercice:

On considère le mot « manger »

- 1) Combien a-t-il de préfixe ?
- 2) Combien a-t-il de facteurs?
- 3) Combien a-t-il de sous-mots?

factorisation

Soient $m, f_1, f_2,f_k \in A^*$ ($k \ge 1$). La suite (f_1, f_2,f_k) est une **factorisation** de m lorsque $m = f_1 \bullet f_2 \bullet \bullet f_k$.

Exemple:

manger= ma•ng•ε•er donc

(ma, ng, ϵ , er) est une factorisation du mot manger en 4 facteurs.

15

Un <u>langage</u> est un sous-ensemble de X*

<u>par exemple</u>: Soit X={a, b}: L={ $m \in X^*/|m|_a = 2$ } ={ aa, aab, aba, baa,...}

Remarques:

- L'alphabet X est fini (donc dénombrable)
- L'ensemble X* de tous les mots est infini (sauf si X=Ø)
 mais dénombrable (i.e. en bijection avec IN). Donc
 un langage est dénombrable.
- L'ensemble de tous les langages *n'est pasdénombrable.*

Ordre lexicographique sur X*

On suppose que X est muni d'un ordre *total* \leq_X (appelé *ordre alphabétique*).

Ordre lexicographique sur X* (≤_{X*}):

- 1) Si m_1 est **préfixe** de m_2 alors $m_1 \leq_{X^*} m_2$.
- 2) Si $m_1 = u \cdot m'_1$ et $m_2 = u \cdot m'_2$ avec m'_1 et $m'_2 \neq \varepsilon$, et $m'_1[1] \neq m'_2[1]$, (éventuellement $u = \varepsilon$) alors: $\mathbf{m_1} \leq_{\mathsf{X}^*} \mathbf{m_2}$ ssi $\mathbf{m'_1[1]} \leq_{\mathsf{X}} \mathbf{m'_2[1]}$,

Remarque: \leq_{x^*} est total

17

Exemple :ordre lexicographique

 $X=\{a,b\}$ avec $a \leq_x b$:

 $ab \leq_{X^*} abb$ $ababb \leq_{X^*} abb$ $aaaaa \leq_{X^*} b$ $aaab \leq_{X^*} aab$

Ordre hiérarchique sur X*

On classe les mots par longueur croissante (un mot plus court est classé avant un mot plus long)

A longueur égale, les mots sont classés suivant l'ordre lexicographique.

19

Exemple :ordre hiérarchique

 $b \le_H aa$ $aab \le_H abb$ $aa \le_H aaa$ $aab \le_H aaab$ $abb \le_H abba$

Exercice:

1) Donnez, dans l'ordre hiérarchique, les 5 premiers mots du langage

L={
$$m \in X*/ |m|_a = 2$$
}

- 2) Même question avec l'ordre lexicographique.
- 3) Reprendre les questions précédentes avec le langage

L'= $\{ m \in X*/ bb \text{ facteur de } m \}$

TD sur les langages formels

Exercice 1:

Soit $X = \{a, b, c\}$ un alphabet et m = abca un mot sur X. Donner tous les facteurs, les suffixes, les préfixes et les sous-mots de m.

Exercice 2:

Soit m = aba. Combien y a-t-il de factorisations de m:

- 1. en deux facteurs différents de ε ?
- 2. en deux facteurs quelconques?
- 3. en trois facteurs différents de ε ?
- 4. en trois facteurs quelconques?

Exercice 3:

Soit $X = \{a, b\}$ un alphabet et C le sous-ensemble de mots de X^* ayant aba comme facteur et b^3 comme sous-mot.

- 1. Quelle est la longueur minimale k_0 des mots de C?
- 2. Combien y a-t-il dans C de mots de longueur k_0 ?
- 3. Soit $k \ge 0$ un entier. Quel est en fonction de k le nombre de mots de C de longueur inférieure ou égale à k et n'ayant pas a^3 comme sous-mot ?

Exercice 4:

Soit $X = \{a, b\}$ un alphabet muni de la relation d'ordre totale \leq telle que $a \leq b$. On énumère les mots de X^* suivant l'ordre hiérarchique: le numéro 1 est le plus petit mot suivant l'ordre hiérarchique (donc ε), le numéro 2 est le suivant, ...

- 1. Donner les 10 premiers mots.
- 2. Soit k un entier strictement positif. Donner en fonction de k le nombre de mots de longueur strictement inférieure à k. En déduire le numéro de a^k .
- 3. Quel est le numéro de m = abaabbbab?
- 4. Quel est le mot de X^* dont le numéro est 300 ?

Exercice 5:

Soient X un alphabet, A et B deux langages sur X^* . On note $A \bullet B$ le langage de X^* défini par

$$A \bullet B = \{u \bullet v, u \in A \land v \in B\}$$

Pour les questions suivantes on prendra $X = \{a, b\}$. Calculer $A \bullet B$:

- 1. $A = \{a, ab, bb\}$ et $B = \{\varepsilon, b, aa\}$.
- 2. $A = \emptyset \text{ et} B = \{a, ba, bb\}$.
- 3. $A = \{\varepsilon\}$ et $B = \{b, aba\}$
- 4. $A = \{aa, ab, ba\}$ et $B = X^*$.

Exercice 6:

Soient $X = \{a, b\}$ un alphabet et L un langage sur X^* . On définit $Pref(L) = \{u \in X^*, \exists v \in L, u \text{ préfixe de } v\}$. Déterminer Pref(L) dans chacun des cas suivants:

- 1. $L_1 = \{a^n b^n, n \ge 0\}.$
- 2. $L_2 = \{a^n b^m, 0 \le n \le m\}.$
- 3. $L_3 = \{a^n b^m, 0 \le m \le n\}$
- 4. $L_4 = \{u \in X^*, |u|_a = |u|_b\}$

Chapitre 2. Automates déterministes

2) Automates déterministes

2a) <u>définitions</u>:

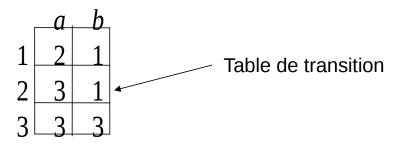
Un automate fini est un quintuplet $A = (X,E, e_0, F,\sigma)$ où:

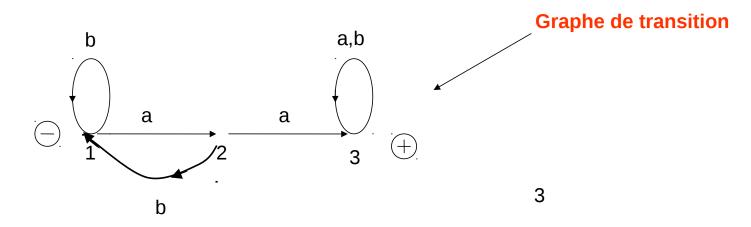
- X est un ensemble fini, appelé alphabet.
- E est un ensemble fini, appelé ensemble des états. (X et E disjoints)
- −e₀ est un élément distingué de E, appelé état initial.
- F est un sous-ensemble de E, appelé ensemble des états finaux.
- σ est une application de ExX dans E, appelée fonction de transition.

Exemple d'automate fini: A₁

$$X=\{a,b\}; E=\{1,2,3\}; e_0=1; F=\{3\};$$

 $\sigma:(1,a) \to 2; (2,a) \to 3; (3,a) \to 3; (1,b) \to 1; (2,b) \to 1; (3,b) \to 3;$





• <u>Définition 2</u>:

On étend la fonction de transition σ à une application σ^* de ExX* dans E en posant, pour tout $m \in X^*$ et tout $e \in E$:

- Si m= ε alors $\sigma^*(e,m)=e$
- -Si m = x m' avec x \in X et m' \in X*, et si σ (e,x)=e',alors:

$$\sigma^*(e,m) = \sigma^*(e,x \bullet m') = \sigma^*(\sigma(e,x),m') = \sigma^*(e',m')$$

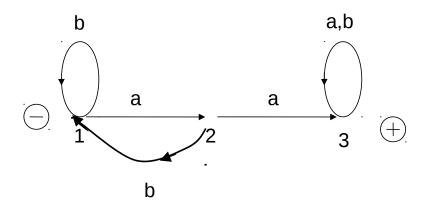
Il est commode de noter e x m = $\sigma^*(e,m)$.

La dernière ligne de la définition s'écrit donc: e \mathbf{x} m=e \mathbf{x} ($\mathbf{x} \bullet$ m')= (e \mathbf{x} x) \mathbf{x} (m')=e' \mathbf{x} m'

Exemple avec A₁

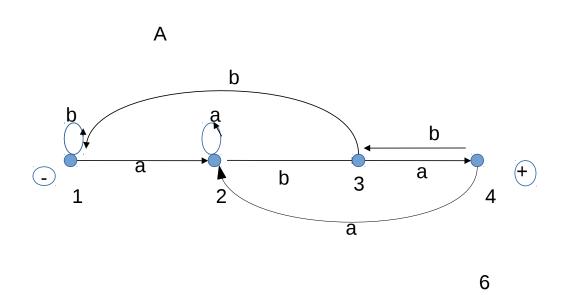
$$\sigma^*(1,abaab) = \sigma^*(2,baab) = \sigma^*(1,aab)$$
$$= \sigma^*(2,ab) = \sigma^*(3,b) = \sigma^*(3,\epsilon) = 1$$

On écrira: $1 \times abaab = 3$

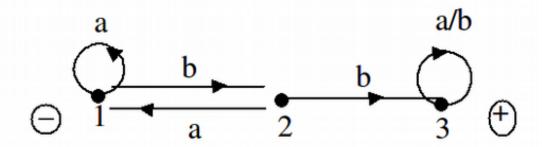


Exemple:

1 x bbaabab = 3 1X babbababa = 4 2 x aabbb = 1



Exercice:



1Xabba=?

1Xaaabab=?

2Xaab= ?

1Xu•bb•v=? (u et v mots quelconques)

• Propriété 1:

Pour tout u,
$$v \in X^*$$
, $\sigma^*(e, u \cdot v) = \sigma^*(\sigma^*(e, u), v)$
 $e \times u \cdot v = (e \times u) \times v$

- <u>Démonstration</u>: on démontre par récurrence sur k la proposition suivante:
 - P(k): $\forall e \in E, \forall u, v \in X^*, |u| = k \Rightarrow e \times (u \cdot v) = (e \times u) \times v$

2 b) Langages reconnus par un automate déterministe:

Définition3:

Soit $A=(X, E, e_0, F, \sigma)$ un automate. Le langage reconnu par **A** est le langage:

$$L(A)=\{ m\in X^*/ e_0 \times m\in F \}$$

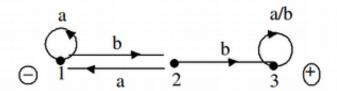
Le chemin étiqueté:

Soit A = (X,E, e_0, F,σ) un automate, e un état de E et m= $a_1a_2...a_k$ un mot de X*. On note:

$$\land (e,m)=(t_0=e, a_1, t_1, a_2,a_i, t_i,a_k, t_k)$$

avec
 $\forall i \in \{0,1,...,k\}, t_i \in E,$
 $\forall i \in \{0,1,...,k-1\}, t_i \times a_{i+1} = t_{i+1}$

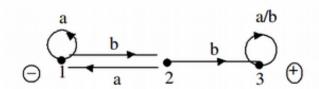
Exemple de chemin étiqueté :



 $\Lambda(1,aabbabb)=(1,a,1,a,1,b,2,b,3,a,3,b,3,b,3,b,3)$ Première fois dans l'état 3

$$1 \xrightarrow{a} 1 \xrightarrow{a} 1 \xrightarrow{b} 2 \xrightarrow{b} 3 \xrightarrow{a} 3 \xrightarrow{b} 3 \xrightarrow{b} 3$$

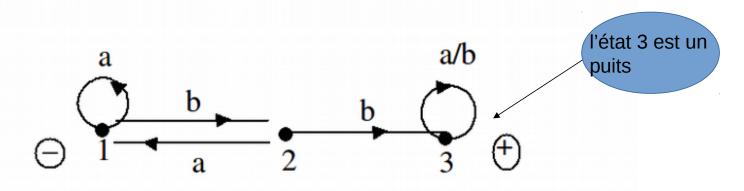
Démonstration de langage :



L(A) = $\{m \in X^*, bb \text{ facteur de m}\} = \{u \cdot bb \cdot v, u, v \in X^*\}$?

1) $1Xu \cdot bb \cdot v = 3$?

2) Si 1Xm = 3 alors bb facteur de m?



1Xu•bb•v= 3? (u et v mots quelconques)

Démonstration:

1er cas: 1xu=1 alors:

 $1xu \cdot bb \cdot v = (1xu)Xbb \cdot v = (1xbb)xv = 3xv = 3$

(dernière égalité : l'état 3 est un puits)

2ème cas : 1xu=2 alors :

 $1xu \cdot bb \cdot v = (1xu)Xbb \cdot v = (2xbb)xv = 3xv = 3$

3ème cas: 1xu=3 alors:

 $1xu \cdot bb \cdot v = (1xu)xbb \cdot v = (3xbb)xv = 3xv = 3$

Si 1Xm=3 alors bb facteur de m?

Par hypothèse $\Lambda(1,m)$ est de la forme :

$$\Lambda(1,m)=(t_0=1,...,b,t_{i-1}=2,b,t_i=3,..,3,..,3,..,t_k=3)$$

Donc bb facteur de m

(explications:

Par hypothèses : $t_0=1$ et $t_k=3$.

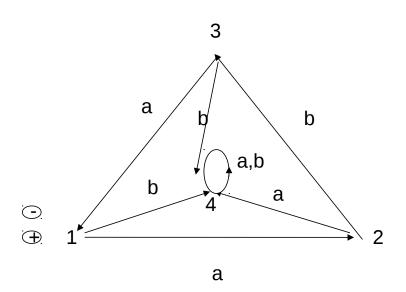
Notons i le plus petit indice tel que t_i=3

Par analyse « rétro » de l'automate :

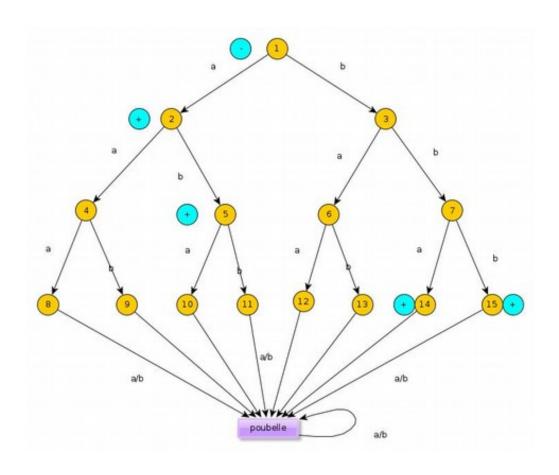
 $t_{i-1}=2$, $a_i=b$ et $a_{i-1}=b$

Exemple 2: A₂

• A₂



Automate reconnaissant un langage fini L(A)={a,ab,bba,bbb}



Automate reconnaissant le complémentaire de L(A)

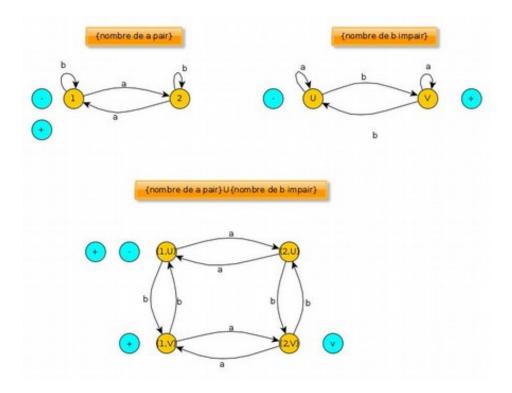
Si

 $A=(X,E,e_0,F,\sigma)$ est un automate reconnaissant L(A)

alors

A'=(X,E,e₀,E-F,σ) est un automate reconnaissant le complémentaire de L(A) (les états finaux de A' sont ceux qui ne sont pas finaux dans A)

Automate reconnaissant L(A) U L(A')



Automate reconnaissant l'intersection de L(A) et L(A')

La construction est la même que pour l'union mais les états finaux sont ceux qui sont finaux à la fois pour A et pour A' (ce sont les couples qui appartiennent à FXF')

Exercice 1:

Dressez le diagramme de transition de l'automate reconnaissant tous les mots **n'ayant pas abb facteur** et uniquement ces mots.

Exercice 2

Dressez le diagramme de transition de l'automate reconnaissant tous les mots ayant **ab suffixe et le mot \epsilon** (et uniquement ces mots).

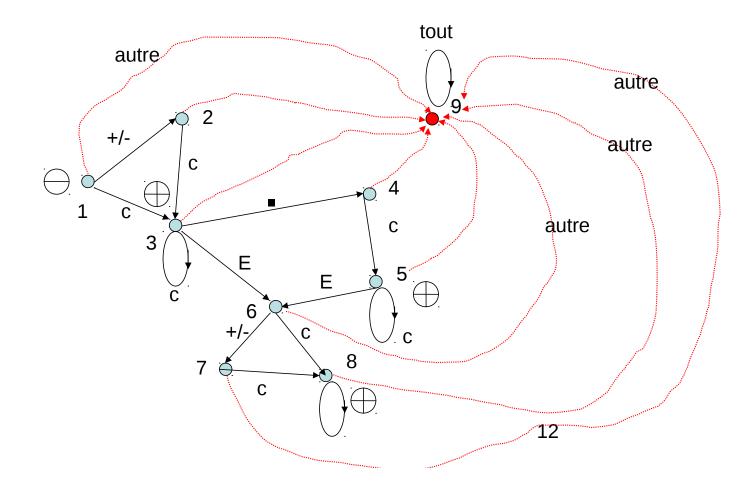
Exemple: un automate reconnaissant les constantes réelles.

Les constantes réelles (en pascal par ex.):

(pour simplifier on ne donnera pas de statut particulier à 0. On acceptera donc l'écriture 003.00E-005)

<u>L'alphabet est donc</u>:

Les chiffres ayant le même statut, on notera plus simplement C



2 C)Programmation des automates finis:

Algorithme ReconnaissanceParUnautomateDéterministe

Données: un automate $A=(X, E, e_0, F, \sigma)$ et un mot $m \in X^*$

Résultat: retourne vrai si $m \in L(A)$.

$$e \leftarrow e_0$$

 $i \leftarrow 0$
tantque $i < |m|$ faire
 $i \leftarrow i + 1$
 $e \leftarrow e \times m[i]$
retourner $(e \in F)$

2 d)Un langage non reconnaissable:

Langage des parenthèses défini sur X={a,b}:

C'est un langage de X* noté LP défini par:

melp
$$\Leftrightarrow$$
 1) $|m|_a = |m|_b$

2) Pour tout u *préfixe* de m on a $|u|_a \ge |u|_b$

2 d)Un langage non reconnaissable:

Propriété 2:

Il n'existe aucun automate A tel que LP = L(A).

Quelques mots de LP

Les mots ε, ab, aabb, aabbab, a¬b¬, aababaabbb sont dans LP.

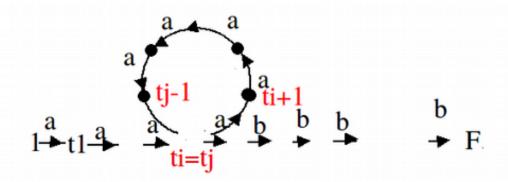
Le mot aaababbbabbaab n'est pas dans LP

Idée de la démonstration :

Par l'absurde :

Si l'automate existait alors, pour tout entier $n, 1 \times a^n b^n \in F$.

Si n est supérieur au nombre d'état de l'automate:



Définition 4:

Les langages rationnels sont les langages reconnaissables par des automates finis.

(LP n'est donc pas rationnel)

Langages rationnels

Si L et L' sont deux langages rationnels alors :

- 1) l'union de L et L' est rationnel.
- 2) l'intersection de L et L' est rationnel.
- 3) Le complémentaire de L est rationnel.
- 4) L•L' est rationnel

Exercices - Automates déterministes

Dans les exercices suivants, $X = \{a, b\}$.

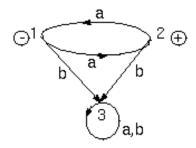
Exercice 1

Soit $A = (X, E, e_0, F, \sigma)$ l'automate défini par : $X = \{a, b\}, E = \{1, 2, 3\}, e_0 = 1, F = \{3\}, \sigma(1, a) = 2, \sigma(1, b) = 1, \sigma(2, a) = 2, \sigma(2, b) = 3, \sigma(3, a) = 3, \sigma(3, b) = 3.$

- 1. Donner la table et le graphe de transition de A.
- 2. Les mots bbabb, aabaa, bbaaa appartiennent-ils au langage L(A)?
- 3. Donner tous les mots de L(A) de longueur inférieure ou égale à 3.
- 4. Déterminer L(A). (Preuve)

Exercice 2

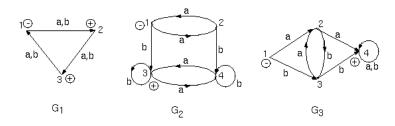
Soit A l'automate sur X dont le graphe de transition est



- 1. Déterminer $X,\,E,\,e_0,\,F,\,\sigma$ tels que $A=(X,E,e_0,F,\sigma).$
- 2. Donner tous les mots de L(A) de longueur inférieure ou égale à 5.
- 3. Déterminer L(A). (Preuve)

Exercice 3

Soit A_1 , A_2 , A_3 les automates de graphes de transition G_1 , G_2 , G_3 .



Pour i de 1 à 3,

1. Donner les 7 premiers mots de $L(A_i)$ suivant l'ordre sur X^* : par longueur croissante et à longueur égale suivant l'ordre lexicographique.

- 2. Donner, si c'est possible, les 7 premiers mots de $L(A_i)$ suivant l'ordre lexicographique sur X^* .
- 3. Déterminer $L(A_i)$.

Exercice 4

Soit $X = \{a, b\}$. Pour i de 1 à 8, dessiner le graphe de transition G_i d'un automate A_i reconnaissant le langage L_i .

- 1. L_1 : ensemble des mots de X^* ayant aa comme sous-mot,
- 2. L_2 : ensemble des mots de X^* ayant aa comme facteur,
- 3. L_3 : ensemble des mots de X^* ayant aa comme préfixe,
- 4. L_4 : ensemble des mots de X^* ayant aa comme suffixe,
- 5. $L_5 = \{ab\},\$
- 6. $L_6 = \{(ab)^n, n \ge 0\},\$
- 7. $L_7 = \{m \in X^* \mid |m|_b \mod 3 = 1\}, (L_7 \text{ est l'ensemble des mots de } X^* \text{ dont le nombre de } b \text{ modulo } 3 \text{ est égal à } 1),$
- 8. $L_8 = \{ m \in X^* \mid |m|_b \mod 3 \neq 1 \},\$
- 9. $L_9 = \{ m \in X^* \mid |m|_a \text{ est pair } \},$
- 10. $L_{10} = L_7 \cap L_9$,
- 11. $L_{11} = L_7 \cup L_9$.

Exercice 5

Les langages suivants sont-ils rationnels? (si oui, dessiner le graphe de transition d'un automate reconnaissant ce langage)

$$L_1 = \{a^n b^p, n \ge 1, p \ge 1\},\$$

$$L_2 = \{a^n b^p, n \ge 0, p \ge 0\},\$$

$$L_3 = \{a^n b^n, n \ge 0\},\$$

$$L_4 = \{a^n b^p, n > p \ge 0\},\$$

$$L_5 = \{(ab)^n, n \ge 1\}.$$

Exercice 6

On considère $A=(X,E,e_0,F,\sigma)$ l'automate défini par : $X=\{a,b\}, E=\{1,2,3,4\},$ $e_0=1, F=\{4\}, \ \sigma(1,a)=2, \ \sigma(1,b)=1, \ \sigma(2,a)=3, \ \sigma(2,b)=1, \ \sigma(3,a)=4,$ $\sigma(3,b)=1, \ \sigma(4,a)=4, \ \sigma(4,b)=4.$

- 1. (a) Donner sans justification, le graphe de transition de l'automate A.
 - (b) Les mots a^2b^2a et ba^3b^2 appartiennent-ils au langage L(A)?
 - (c) Donner sans justification les six premiers mots de L(A) rangés
 - i. par ordre de longueur croissante et à longueur égale suivant l'ordre lexicographique ;
 - ii. par ordre lexicographique, si c'est possible.

- (d) Donner sans justification, le graphe de transition d'un automate reconnaissant $L(A) \cup \{\varepsilon\}$.
- 2. Soit $L = \{m \in X^*, \exists u, v \in X^* \mid m = u \cdot a^3 \cdot v\}$. Montrer que L(A) = L.
- 3. Pour tout langage U sur X, on note U^* le langage sur X contenant les mots pouvant se factoriser en un nombre éventuellement nul de facteurs appartenant à U, c'est-à-dire

$$U^* = \{\varepsilon\} \cup \{m \in X^* \mid \exists k \in \mathbf{N}, k \ge 1, \exists m_1, m_2, ..., m_k \in U, m = m_1 \cdot m_2 \cdot ... \cdot m_k\}$$

Soit $L_1 = \{a^3, b\}$.

- (a) Donner sans justification les six premiers mots de L_1^* rangés
 - i. par ordre de longueur croissante et à longueur égale suivant l'ordre lexicographique;
 - ii. par ordre lexicographique, si c'est possible.
- (b) Donner sans justification, le graphe de transition d'un automate reconnaissant L_1 .
- (c) Donner sans justification, le graphe de transition d'un automate reconnaissant L_1^* .
- (d) Donner sans justification, le graphe de transition d'un automate reconnaissant $L_1^* \cap L$.

Exercice 7

On considère $A=(X,E,e_0,F,\sigma)$ l'automate défini par : $X=\{a,b\},\ E=\{1,2,3\},$ $e_0=1,\ F=\{3\},\ \sigma(1,a)=2,\ \sigma(1,b)=3,\ \sigma(2,a)=2,\ \sigma(2,b)=3,\ \sigma(3,a)=3,$ $\sigma(3,b)=3.$

- 1. Donner sans justification, le graphe de transition de l'automate A.
- 2. Les mots a^2b^2a et a^4 appartiennent-ils au langage L(A)?
- 3. Donner sans justification, si c'est possible, les cinq premiers mots de L(A) rangés
 - (a) par ordre de longueur croissante et à longueur égale suivant l'ordre lexicographique;
 - (b) par ordre lexicographique.
- 4. Démontrer que le langage L_1 reconnu par l'automate A, est l'ensemble de tous les mots de X^* contenant au moins un b.
- 5. Donner sans justification, le graphe de transition d'un automate A_1 ayant moins d'états que A tel que $L(A_1) = L_1$.
- 6. Donner sans justification, le graphe de transition d'un automate reconnaissant le langage
 - (a) $L_2 = L_1 \cup \{\varepsilon\}$;
 - (b) $L_3 = L_1 \cup \{a\}$;
 - (c) $L_4 = \{m \in X^*, |m| \text{ est pair } \};$
 - (d) $L_5 = L_1 \cap L_4$.